Машинное обучение
Семинар №1
Понижение размерности и метод главных компонент

В машинном обучении часто возникает задача уменьшения размерности признакового пространства. Для этого можно, например, удалять признаки, которые слабо коррелируют с целевой переменной; выбрасывать признаки по одному и проверять качество модели на тестовой выборке; перебирать случайные подмножества признаков в поисках лучших наборов.

Ещё одним из подходов к решению задачи является поиск новых признаков, каждый из которых является линейной комбинацией исходных признаков. В случае использования квадратичной функции ошибки при поиске такого приближения получается *метод главных компонент* (principal component analysis, PCA), о котором и пойдет речь.

Существует несколько разных постановок метода главных компонент. Мы разберём некоторые из них.

1 Максимизация дисперсии

Задача 1.1. *Рассмотрим многомерную случайную величину* $(X_1, \ldots, X_D)$. *Пусть у неё нулевое математическое ожидание. Мы собрали для такой случайной величины* ℓ *наблюдений и записали их в виде матрицы* $X \in \mathbb{R}^{\ell \times D}$. *Найдите выборочную ковариационную матрицу для выборки* X.

Решение. Нам надо найти ковариационную матрицу между столбцами матрицы X. На её диагонали будут стоять дисперсии. Обычно $Var(X_j) = \mathbb{E}(X_j^2) - \mathbb{E}^2(X_j)$. Так как математическое ожидание каждого столбца равно нулю, тогда $Var(X_j) = \mathbb{E}(X_j^2)$, и оценку таких дисперсий можно найти по формуле

$$\hat{\sigma}_j^2 = \frac{1}{\ell} \sum_{i=1}^{\ell} x_{ij}^2.$$

В остальных клетках матрицы будут стоять выборочные ковариации. Обычно $\mathrm{Cov}(X_j, X_k) = \mathbb{E}(X_j X_k) - \mathbb{E}(X_j)\mathbb{E}(X_k)$. Так как математическое ожидание каждого столбца равно нулю, тогда $\mathrm{Cov}(X_j, X_k) = \mathbb{E}(X_j X_k)$, и их оценки можно найти по формуле

$$\hat{\rho}_{jk} = \frac{1}{\ell}\sum_{i=1}^{\ell} x_{ij} \cdot x_{ik}.$$

Получается, что выборочную ковариационную матрицу можно записать как $\frac{X^T X}{\ell}$. В вычислениях ниже нам будет часто встречаться матрица $X^T X$. Будем держать в голове, что она пропорциональна выборочной ковариационной матрице. Отметим, что если бы математическое ожидание было бы неизвестно, для получения несмещённой оценки дисперсии и ковариации мы должны были бы делить на $\ell - 1$.

■

Пусть $X \in \mathbb{R}^{\ell \times D}$ — матрица «объекты-признаки», где ℓ — число объектов, а D — число признаков. Будем считать, что данные являются центрированными — то есть среднее в каждом столбце матрицы X равно нулю. Мы хотим уменьшить размерность пространства до d. При этом каждый новый признак будет линейно выражаться через исходные с какими-то весами

$$z_{ij} = \sum_{k=1}^{D} x_{ik} u_{kj}.$$

Чем больше дисперсии выборки мы сохранили, тем больше сохраняется информации. Будем искать веса $u_1, \ldots, u_D \in \mathbb{R}^D$ так, чтобы сохранить максимальную дисперсию:

1. $z_1 = Xu_1$: выборочная дисперсия z_1 должна быть максимальной при условии $\|u_1\|^2 = 1$.
2. $z_2 = Xu_2$: выборочная дисперсия z_2 должна быть максимальной при условии $\|u_2\|^2 = 1$ и $u_1 \perp u_2$.
3. $z_3 = Xu_3$: выборочная дисперсия z_3 должна быть максимальной при условии $\|u_3\|^2 = 1$ и $u_1 \perp u_3, u_2 \perp u_3$
4. и так далее

В матричном виде мы можем записать это как $Z = XU$. При этом матрица U будет ортогональной, то есть $U^T U = I$. Нам это нужно, чтобы задача оптимизации имела единственное решение.

Давайте попробуем найти первую главную компоненту. Сведём все требования к ней в оптимизационную задачу. Данные нормированы. Преобразование предполагает, что мы взвесим исходные случайные величины с какими-то весами. Получается, что математическое ожидание по-прежнему будет нулевым, и выборочная дисперсия будет совпадать со вторым моментом

$$\begin{cases} \|Xu_1\|^2 = u_1^T X^T X u_1 \to \max_{u_1} \\ \|u_1\|^2 = u_1^T u_1 = 1. \end{cases}$$

Запишем лагранжиан (знак минус перед λ используется для удобства):

$$L(u_1, \lambda) = u_1^T X^T X u_1 - \lambda(u_1^T u_1 - 1).$$

Продифференцируем его и приравняем нулю:

$$\frac{\partial L}{\partial u_1} = 2X^T X u_1 - 2\lambda u_1 = 0.$$

Получается, что

$$X^T X u_1 = \lambda u_1$$

Отсюда получаем, что u_1 должен быть собственным вектором матрицы $X^T X$. Учтём это и преобразуем функционал:

$$\|Xu_1\|^2 = u_1^T X^T X u_1 = \lambda u_1^T u_1 = \lambda \to \max_{u_1}$$

Значит, собственный вектор u_1 должен соответствовать максимальному собственному значению матрицы $X^T X$. Напомним, что эта матрица пропорциональна ковариационной матрице. То есть именно она характеризует дисперсию выборки.

Для следующих компонент к оптимизационной задаче будут добавляться требования ортогональности предыдущим компонентам. Решая эти задачи, мы получим, что главная компонента u_i равна собственному вектору, соответствующему i-му собственному значению.

После того, как найдены главные компоненты, можно проецировать на них и новые данные. Если нам нужно работать с тестовой выборкой X', то её проекции вычисляются как $Z' = X' U_d$.

Задача 1.2. *Давайте убедимся, что мы поняли метод главных компонент и попробуем ответить на следующие вопросы:*

1. *Чему будет равно среднее z_1, если исходные данные центрированы? А z_2?*
2. *Докажите, что из того, что $u_1 \perp u_2$ следует, что $z_1 \perp z_2$. Чему будет равна $\mathrm{Cov}(z_1, z_2)$?*
3. *Докажите, что $Var(x_1) + \ldots + Var(x_D) = Var(z_1) + \ldots + Var(z_D)$*
4. *Выразите $\sum_{k=1}^{D} \|z_k\|^2$ через собственные числа. Как с помощью собственных чисел оценить долю объяснённой компонентами дисперсии?*

Решение.

1. Все исходные переменные центрированы, их математическое ожидание равно нулю. Мы взвешиваем случайные величины с какими-то весами. Математическое ожидание от этого никак не меняется. Оно остаётся нулевым.

2. Из ортогональности u_1 и u_2 следует ортогональность z_1 и z_2

   $$z_1^T z_2 = u_1^T X^T X u_2 = \lambda_2 \cdot u_1^T u_2 = 0.$$

   Тут мы воспользовались тем, что u_2 это собственный вектор матрицы $X^T X$. Выходит, что

   $$\mathrm{Cov}(z_j, z_k) = \mathbb{E}(z_j \cdot z_k) - \mathbb{E}(z_j) \cdot \mathbb{E}(z_k) = \mathbb{E}(z_j \cdot z_k) = z_j^T z_k = 0.$$

3. С одной стороны

$$Var(x_1) + \ldots + Var(x_D) = \frac{1}{\ell - 1} \operatorname{tr}(X^T X),$$

так как все дисперсии в ковариационной матрице находятся на диагонали, а след представляет из себя сумму диагональных элементов.

С другой стороны

$$Var(z_1) + \ldots + Var(z_D) = \frac{1}{\ell - 1} \operatorname{tr}(Z^T Z) = \frac{1}{\ell - 1} \operatorname{tr}(U^T X^T X U) = \frac{1}{\ell - 1} \operatorname{tr}(X^T X),$$

так как $U^T U = I$, под следом матрицы можно переставлять по циклу и, снова, все дисперсии находятся в матрице $Z^T Z$ на диагонали. Обратите внимание, что все недиагональные элементы в $Z^T Z$ будут нулевыми. Мы доказали это в предыдущем пункте.

4. Так как все математические ожидания нулевые, $\|z_k\|^2 = z_k^T z_k = Var(z_k)$. Выходит, что $\sum_{k=1}^{D} \|z_k\|^2 = \sum_{k=1}^{D} Var(z_k) = \sum_{k=1}^{D} Var(x_k)$. Выразим эту сумму через собственные значения

$$\sum_{k=1}^{D} \|z_k\|^2 = \sum_{k=1}^{D} \|X u_k\|^2 = \sum_{k=1}^{D} u_k^T X^T X u_k = \sum_{k=1}^{D} u_k^T \lambda_k u_k = \sum_{k=1}^{D} \lambda_k.$$

Выходит, что если мы оставляем в данных d компонент, то дробь $\frac{\lambda_1 + \ldots + \lambda_d}{\lambda_1 + \ldots + \lambda_D}$ показывает, какая доля дисперсии сохранилась после проецирования выборки на главные компоненты.

■

Задача 1.3. *Фил придумал метод бесполезных компонент. Как и в методе главных компонент, бесполезные компоненты являются линейными комбинациями исходных переменных. Бесполезные компоненты также ортогональны между собой. Вектор весов, с которыми исходные переменные входят в бесполезную компоненту, всегда имеет единичную длину. В отличие от метода главных компонент, первая бесполезная компонента обладает наименьшей выборочной дисперсией. Вторая бесполезная компонента ортогональна первой и обладает наименьшей выборочной дисперсией при условии ортогональности. И так далее.*

Как связаны метод бесполезных компонент и метод главных компонент?

Решение. Компоненты из метода бесполезных компонент — это ровно главные компоненты, но только перечисленные в обратном порядке.

■

2 Минимизация ошибки приближения

Пусть $X \in \mathbb{R}^{\ell \times D}$ — матрица «объекты-признаки», где ℓ — число объектов, а D — число признаков. Поставим задачу уменьшить размерность пространства до d. Будем считать, что данные являются центрированными — то есть среднее в каждом столбце матрицы X равно нулю.

Мы хотим, чтобы каждый новый признак линейно выражался через исходные

$$z_{ij} = \sum_{k=1}^{D} x_{ik} u_{kj}.$$

В матричном виде это можно записать как

$$Z = XU^T.$$

Чтобы у этого уравнения существовало единственное решение, нужно ввести на матрицу весов ограничения. Пусть она будет ортогональной $U^T U = I$. Если это требование выполнено, можно получить формулу для матрицы X

$$X = ZU.$$

В матрице Z будет меньше признаков, чем в X, так как $d < D$. Это равенство нельзя выполнить строго. Нам придётся потребовать, чтобы отклонение матрицы признаков X от ZU было как можно меньше. Размер этого отклонения будем вычислять с помощью нормы Фробениуса:

$$\begin{cases} ||X - ZU||_F \to \min_{Z,U} \\ U^T U = I \end{cases}$$

Норма Фробениуса матрицы — это сумма квадратов ее значений. Получившаяся задача — это задача матричного разложения. Необходимо представить матрицу X в виде произведения двух матриц U и W, которые будут иметь меньший ранг. То есть нужно уменьшить ранг матрицы, при этом потеряв как можно меньше информации в ней.

Решением данной задачи также являются собственные векторы ковариационной матрицы.

3 Задачи на метод главных компонент[1]

Задача 3.1. *У бесстрашного исследователя Ильдуса есть набор точек* $(x_1, y_1), \ldots, (x_n, y_n)$. *Ильдус находит прямую, сумма расстояний от которой до каждой точки минимальна. Верно ли, что прямая проходит через точку* $(\bar{x}, \bar{y})$*?*

Решение. Да. Например, прямую можно задать вектором w единичной длины и числом b, $w^T \begin{pmatrix} x \\ y \end{pmatrix} = b$. Обозначим вектор $(x_i, y_i)^T$ буквой v_i. Тогда нам нужно минимизировать функцию

$$\sum (w^T v_i - b)^2.$$

[1]Задачи взяты из коллекции Бориса Демешева: https://github.com/bdemeshev/mlearn_pro

Дифференциируем по b и получаем $\sum w^T v_i = n \cdot b$, что и означает, что прямая проходит через среднюю точку,

$$w^T \begin{pmatrix} \bar{x} \\ \bar{y} \end{pmatrix} = b.$$

■

Задача 3.2. *Есть две переменных,* $x_1 = (1, 0, 0, 3)^T$, $x_2 = (3, 2, 0, 3)^T$. *Найдите первую и вторую главные компоненты.*

Решение. Матрица с центрированными столбцами имеет вид: $\widetilde{X} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \\ -1 & -2 \\ 2 & 1 \end{pmatrix}$

Тогда $\widetilde{X}^T \widetilde{X} = \begin{pmatrix} 6 & 4 \\ 4 & 6 \end{pmatrix}$.

Её собственные числа: $\lambda_1 = 10$, $\lambda_2 = 2$, собственные вектора $u_1 = (1/\sqrt{2} \quad 1/\sqrt{2})^T$, $u_2 = (1/\sqrt{2} \quad -1/\sqrt{2})$. Найдём главные компоненты:

$$Z = XU = \begin{pmatrix} 0 & 1 \\ -1 & 0 \\ -1 & -2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ -1/\sqrt{2} & -1/\sqrt{2} \\ -3/\sqrt{2} & 1/\sqrt{2} \\ 3/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

Первая и вторая главные компоненты — это первый и второй столбцы матрицы Z соответственно.

■